

## Código R:

```
library("ggplot2"); library("patchwork")


#Parâmetros
inicio <- 4; fim <- 8; n_value <- c(2, 25, 59); seed <- 1681; pop <- 290

var_unif_distr <- ((fim-inicio)**2)/12; val_esperado <- mean(c(fim,inicio)) # Cálculos para a curva
dados <- matrix(nrow = pop, ncol = 3)
for (n in 1:3) {
  set.seed(seed)
  for(i in 1:pop) {
    dados[i,n] <- mean(runif(n_value[n], inicio, fim))
  }
}

dados <- data.frame(dados) # Passar dematriz a DataFrame para poder utilizar no ggplot

gráficos <- list() # Gráficos
for (i in 1:3) {
  gráficos[[i]] <- ggplot(dados, aes_string(colnames(dados)[i])) +
    geom_histogram(aes(y = stat(count/sum(count))),color="purple", fill="#FF00FF", alpha = 0.1, bins = 30) + xlim(inicio, fim) +
    stat_function(fun = dnorm, args = list(mean = val_esperado, sd = (sqrt(var_unif_distr / n_value[i]))), color = "black") +
    labs(title=paste0("Distribuição da Média (n=", n_value[i], ")"),
         x="Valores da Distribuição da Média", y="Frequência Relativa")
}
Reduce("+", gráficos) # Mostrar Gráfico
```

## Gráfico:



### Parâmetros do Exercício

- Semente = 1681
- Nº amostras = 290
- n = 2, 25, 59
- Intervalo = [4,8]

## Comentário

A partir destes histogramas (Frequência Relativa dos valores da distribuição da média) e das respetivas curvas de distribuições normais com valor esperado  $E(X)$  e Variância  $Var(X)/n$ , podemos perceber que as amostras tendem a ficar distribuídas de acordo com a curva. Os histogramas abaixo são histogramas de densidade (obtidos usando  $y = \text{stat}(\text{density})$  no código acima), permitem nos perceber melhor que com o aumento do número de amostras esta tendência verifica-se cada vez mais. O que vai de encontro ao teorema do limite central.

